Московский Государственный Университет имени М. В. Ломоносова

Факультет вычислительной математики и кибернетики

Практикум по курсу
"Распределенные системы"

Улучшение задания jacobi-1d

Отчет

студента 428 учебной группы

Ковтуна Данилы Петрович

Москва, 2021

Содержание

Постановка задачи

Доработать MPI-программу, реализованную в рамках курса “Суперкомпьютеры и параллельная обработка данных”. Добавить контрольные точки для продолжения работы программы в случае сбоя. Реализовать один из 3-х сценариев работы после сбоя:

a) продолжить работу программы только на “исправных” процессах;
b) вместо процессов, вышедших из строя, создать новые MPI-процессы, которые необходимо использовать для продолжения расчетов;
c) при запуске программы на счет сразу запустить некоторое дополнительное количество MPI-процессов, которые использовать в случае сбоя.

Описание алгоритма

Из доступных на старте программы процессов будем оставлять некоторое количество в качестве запасных. Когда какой-нибудь из работающих процессов упадет, будем выделять один из запасных процессов на его место, а итерацию перезапускать на новом коммуникаторе, полученном из старого путем удаления упавших процессов. Пересоздание коммуникатора в таком случае можно запускать после каждой итерации.

Чтобы падения процессов не приводили к падению программы, зарегистрируем обработчик на возврат кодов ошибок из MPI_ функций взаимодействия. На возвращаемые значения функций можно не смотреть, т.к. на каждой итерации у нас происходит MPI_Comm_shrink(), после которого все процессы в коммуникаторе будут живыми.

Операция MPI_Comm_shrink() может перенумеровать процессы, поэтому после её вызова нужно обновлять ранки.

Чтобы сохранять промежуточные вычисления, после каждой итерации для всех работающих процессов будем сохранять матрицы A и B в файлы. В начале итерации будем читать файлы, соответствующие процессу с указанным ранком.

Реализация алгоритма

```
#include "jacobi-1d.h"
#include <mpi.h>
#include <signal.h>
double bench_t_start, bench_t_end;
int size, rank;
MPI_Comm comm;

double *A;
double *B;

static
double rtclock() {
    struct timeval Tp;
    int stat;
    stat = gettimeofday (&Tp, NULL);
    if (stat != 0)
        printf ("Error return from gettimeofday: %d", stat);
    return (Tp.tv_sec + Tp.tv_usec * 1.0e-6);
}


void bench_timer_start() {
    bench_t_start = rtclock ();
}


void bench_timer_stop() {
    bench_t_end = rtclock ();
}


void bench_timer_print() {
    printf ("Time in seconds = %0.6lf\n", bench_t_end - bench_t_start);
}


static
void init_array (int n, double *A, double *B) {
    int i;
    for (i = 0; i < n; i++) {
        A[i] = ((double) i + 2) / n;
        B[i] = ((double) i + 3) / n;
    }
}


static
void print_array(int n, double *A) {
    int i;
```

```
    fprintf(stderr, "==BEGIN DUMP_ARRAYS==\n");
    fprintf(stderr, "begin dump: %s", "A");
    for (i = 0; i < n; i++) {
        if (i % 20 == 0)
            fprintf(stderr, "\n");
        fprintf(stderr, "%0.2lf ", A[i]);
    }
    fprintf(stderr, "==END   DUMP_ARRAYS==\n");
}


static
void kernel_jacobi_1d(int tsteps, int n) {
    int t, i, count, ibeg, iend, right_rank, left_rank;
    MPI_Status status;
    MPI_Request req;
    right_rank = 0;
    left_rank = 0;

    // половина процессов запасные
    size = size / 2 + 1;

    count = (n - 3) / size + 1;
    ibeg = rank * count + 1;
    iend = (rank + 1) * count;
    // Если нитей больше чем данных, которые необходимо обработать
    if (ibeg >= n - 2) {
        ibeg = -1;
        iend = -1;
    }
    // У последней нити, которая попадает в нужный нам диапозон меняем iend на
нужный нам и
    // сообщаем какой у нити ранг процессу size - 1
    if (iend >= n - 3) {
        iend = n - 3;
        right_rank = size - 1;
        MPI_Isend(&rank, 1, MPI_INT, size - 1, 0, comm, &req);
    }
    // У нити size - 1 корректируем ibeg & iend и получаем номер последней
нормальной нити
    if (rank == size - 1) {
        MPI_Recv(&left_rank, 1, MPI_INT, MPI_ANY_SOURCE, 0, comm, &status);
        if (ibeg == -1)
            ibeg = n - 2;
        iend = n - 2;
        //Случай, когда нормально разделилось без постороннего вмешательства
        if (left_rank == right_rank)
            left_rank--;
    }

    if (ibeg != -1) {
```

```
        char fname[50];
        sprintf(fname, "matrixes/A%d.txt\0", rank);
        FILE* fdA = fopen(fname, "w");
        for (int i = 0; i < n; ++i) {
            fprintf(fdA, "%lf ", A[i]);
        }
        fclose(fdA);

        sprintf(fname, "matrixes/B%d.txt\0", rank);
        FILE* fdB = fopen(fname, "w");
        for (int i = 0; i < n; ++i) {
            fprintf(fdB, "%lf ", B[i]);
        }
        fclose(fdB);
    }

    for (t = 0; t < tsteps; t++) {
        static int cnt = 0;
        ++cnt;

        right_rank = 0;
        left_rank = 0;
        count = (n - 3) / size + 1;
        ibeg = rank * count + 1;
        iend = (rank + 1) * count;
        // Если нитей больше чем данных, которые необходимо обработать
        if (ibeg >= n - 2) {
            ibeg = -1;
            iend = -1;
        }
        // У последней нити, которая попадает в нужный нам диапозон меняем iend
на нужный нам и
        // сообщаем какой у нити ранг процессу size - 1
        if (iend >= n - 3) {
            iend = n - 3;
            right_rank = size - 1;
            MPI_Isend(&rank, 1, MPI_INT, size - 1, 0, comm, &req);
        }
        // У нити size - 1 корректируем ibeg & iend и получаем номер последней
нормальной нити
        if (rank == size - 1) {
            MPI_Recv(&left_rank, 1, MPI_INT, MPI_ANY_SOURCE, 0, comm, &status);
            if (ibeg == -1)
                ibeg = n - 2;
            iend = n - 2;
            //Случай, когда нормально разделилось без постороннего вмешательства
            if (left_rank == right_rank)
                left_rank--;
        }

        if (ibeg == -1) {
```

```
            MPIX_Comm_shrink(comm, &comm);
            MPI_Comm_rank(comm, &rank);
            continue;
        }

        char fname[50];
        sprintf(fname, "matrixes/A%d.txt\0", rank);
        FILE* fdA = fopen(fname, "r");
        for (int i = 0; i < n; ++i) {
            fscanf(fdA, "%lf ", &A[i]);
        }
        fclose(fdA);

        sprintf(fname, "matrixes/B%d.txt\0", rank);
        FILE* fdB = fopen(fname, "r");
        for (int i = 0; i < n; ++i) {
            fscanf(fdB, "%lf ", &B[i]);
        }
        fclose(fdB);


        if (cnt == 1 && rank == 1) {
            raise(SIGKILL);
        }

        for (i = ibeg; i <= iend; i++)
            B[i] = 0.33333 * (A[i - 1] + A[i] + A[i + 1]);

        if (rank == 0) {
            if (size != 1) {
                MPI_Send(&B[iend], 1, MPI_DOUBLE, rank + 1, 0, comm);
                MPI_Recv(&B[iend + 1], 1, MPI_DOUBLE, rank + 1, 0, comm,
&status);
            }
        }
        // Кидаем данные левой нити
        else if (rank == size - 1) {
            MPI_Send(&B[ibeg], 1, MPI_DOUBLE, left_rank, 0, comm);
            MPI_Recv(&B[ibeg - 1], 1, MPI_DOUBLE, left_rank, 0, comm, &status);
        }
        // кидаем данные нити size - 1
        else if (right_rank) {
            MPI_Send(&B[iend], 1, MPI_DOUBLE, right_rank, 0, comm);
            MPI_Send(&B[ibeg], 1, MPI_DOUBLE, rank - 1, 0, comm);
            MPI_Recv(&B[iend + 1], 1, MPI_DOUBLE, right_rank, 0, comm, &status);
            MPI_Recv(&B[ibeg - 1], 1, MPI_DOUBLE, rank - 1, 0, comm, &status);
        }
        // Кидаем и получаем данные у соседних нитей
        else {
            MPI_Send(&B[iend], 1, MPI_DOUBLE, rank + 1, 0, comm);
            MPI_Send(&B[ibeg], 1, MPI_DOUBLE, rank - 1, 0, comm);
```

```
            MPI_Recv(&B[iend + 1], 1, MPI_DOUBLE, rank + 1, 0, comm, &status);
            MPI_Recv(&B[ibeg - 1], 1, MPI_DOUBLE, rank - 1, 0, comm, &status);
        }

        // Аналогично для матрицы A
        for (i = ibeg; i <= iend; i++)
            A[i] = 0.33333 * (B[i-1] + B[i] + B[i + 1]);

        if (rank == 0) {
            if (size != 1) {
                MPI_Send(&A[iend], 1, MPI_DOUBLE, rank + 1, 0, comm);
                MPI_Recv(&A[iend + 1], 1, MPI_DOUBLE, rank + 1, 0, comm,
&status);
            }
        }
        else if (rank == size - 1) {
            MPI_Send(&A[ibeg], 1, MPI_DOUBLE, left_rank, 0, comm);
            MPI_Recv(&A[ibeg - 1], 1, MPI_DOUBLE, left_rank, 0, comm, &status);
        }
        else if (right_rank) { // != 0
            MPI_Send(&A[iend], 1, MPI_DOUBLE, right_rank, 0, comm);
            MPI_Send(&A[ibeg], 1, MPI_DOUBLE, rank - 1, 0, comm);
            MPI_Recv(&A[iend + 1], 1, MPI_DOUBLE, right_rank, 0, comm, &status);
            MPI_Recv(&A[ibeg - 1], 1, MPI_DOUBLE, rank - 1, 0, comm, &status);
        }
        else {
            MPI_Send(&A[iend], 1, MPI_DOUBLE, rank + 1, 0, comm);
            MPI_Send(&A[ibeg], 1, MPI_DOUBLE, rank - 1, 0, comm);
            MPI_Recv(&A[iend + 1], 1, MPI_DOUBLE, rank + 1, 0, comm, &status);
            MPI_Recv(&A[ibeg - 1], 1, MPI_DOUBLE, rank - 1, 0, comm, &status);
        }


        sprintf(fname, "matrixes/A%d.txt\0", rank);
        fdA = fopen(fname, "w");
        for (int i = 0; i < n; ++i) {
            fprintf(fdA, "%lf ", A[i]);
        }
        fclose(fdA);

        sprintf(fname, "matrixes/B%d.txt\0", rank);
        fdB = fopen(fname, "w");
        for (int i = 0; i < n; ++i) {
            fprintf(fdB, "%lf ", B[i]);
        }
        fclose(fdB);

        MPIX_Comm_shrink(comm, &comm);
        MPI_Comm_rank(comm, &rank);
    }
```

```
    // Собираем новые данные на нити size - 1
    if (ibeg != -1 && size != 1) {
        if (rank != size - 1) {
            MPI_Send(&B[ibeg], iend - ibeg + 1, MPI_DOUBLE, size - 1, 0, comm);
        }
        else {
            int i;
            for (i = 0; i <= left_rank; i++) {
                MPI_Recv(&B[i * count + 1], (i == left_rank) ? (n - 3 - i *
count) : count, MPI_DOUBLE, i, 0, comm, &status);

            }
        }
    }

    if (ibeg != -1 && size != 1) {
        if (rank != size - 1) {
            MPI_Send(&A[ibeg], iend - ibeg + 1, MPI_DOUBLE, size - 1, 0, comm);
            //printf("%d %d %d\n", rank, ibeg, ibeg + count - 1);
        }
        else {
            int i;
            for (i = 0; i <= left_rank; i++) {
                MPI_Recv(&A[i * count + 1], (i == left_rank) ? (n - 3 - i *
count) : count, MPI_DOUBLE, i, 0, comm, &status);

            }
        }
    }

}


int main(int argc, char *argv[]) {
    int n_s[] = {30, 120, 400, 2000, 4000, 8000, 16000, 32000, 64000};
    int step_s[] = {20, 40, 100, 500, 1000, 2000, 4000, 8000, 16000};
    int i;

    MPI_Init(&argc, &argv);

    comm = MPI_COMM_WORLD;
    MPI_Comm_set_errhandler(comm, MPI_ERRORS_RETURN);
    MPI_Comm_size(comm, &size);
    MPI_Comm_rank(comm, &rank);

    for (i = 0; i < 1; i++) {
        int n = n_s[i];
        int tsteps = step_s[i];

        if (rank == size - 1) {
            printf("n=%d tsteps=%d threads=%d\n", n, tsteps, size);
```

```
        }

        A = (double *) malloc (n * sizeof(double));
        B = (double *) malloc (n * sizeof(double));

        init_array (n, A, B);

        MPI_Barrier(comm);
        if (rank == size - 1) {
            printf("Начато замеряться время\n");
            bench_timer_start();
        }

        kernel_jacobi_1d(tsteps, n);
        MPI_Barrier(comm);

        if (rank == size - 1) {
            bench_timer_stop();
            bench_timer_print();

            //printf("A\n");
            //print_array(n, A);
            printf("B\n");
            print_array(n, B);
        }

        free(A);
        free(B);
    }
    MPI_Finalize();
    return 0;
}
```

Запуск и проверка программы

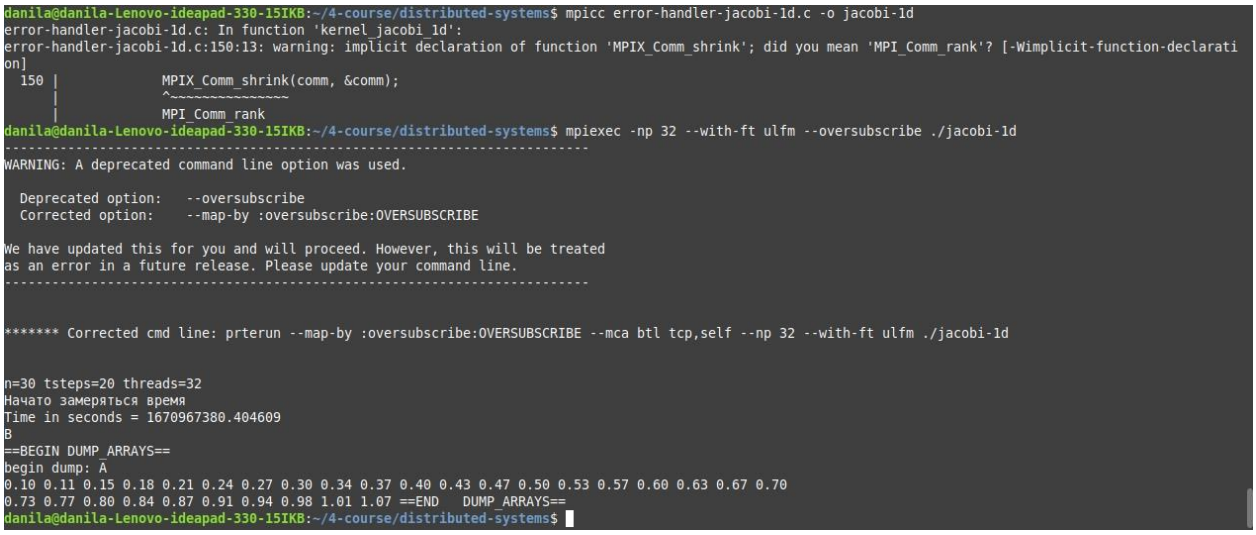

Как мы видим, в ходе работы программы, все было посчитано корректно и был получен правильный вывод несмотря на то, что некоторые процессы были выведены из строя.

Временная оценка

Указанные улучшения надежности приводят к следующим негативным с точки зрения производительности эффектам:

1) Теперь процессы после каждой итерации будут ждать завершения самого медленного из них
2) Тратятся память и время на запись и чтение матриц A и B из файлов
3) На перезапуски итераций в случае падения процессов также уходит дополнительное время
4) Запасные процессы, по сути, простаивают, в то время как они могли бы выполнять некоторую работу. В частности, мы делаем половину процессов запасными, что, без учета предыдущих пунктов приводит к снижению производительности в 2 раза
5) В худшем случае программа будет перезапускаться на каждой итерации, пока не исчерпает свой лимит запасных процессов, после чего все равно упадет.